ISEN Yncréa Ouest

Projet FISA — Intelligence Artificielle

Prédiction de la Présence des Employés via Deep Learning

Smart Workplace — Anticipation de l'occupation des bureaux

Auteurs

Ewan Barre
Baptiste Le-Bail

Année universitaire 2025–2026

Table des matières

1 Introduction

1.1 Contexte : le Smart Workplace

L'essor du travail hybride a profondément transformé l'organisation des espaces de bureau. Dans un contexte de *Smart Workplace*, les entreprises cherchent à optimiser l'utilisation de leurs surfaces : salles de réunion, postes de travail, espaces communs.

Le projet s'inscrit dans ce contexte. À partir de données historiques d'affluence journalière sur une période de 18 mois, nous cherchons à prédire le nombre de présences pour la **semaine suivante** (5 jours ouvrés), en s'appuyant sur des approches d'apprentissage automatique et de *deep learning*.

1.2 Objectifs

— Construire et comparer plusieurs modèles de prédiction de séries temporelles : réseaux récurrents (RNN, LSTM, GRU), gradient boosting (XGBoost) et architectures Transformer (PatchTST, TimeXer, iTransformer, VanillaTransformer).
— Évaluer chaque modèle sur les mêmes métriques (MAE, MAPE, RMSE, R^2) pour une comparaison équitable.
— Identifier la meilleure approche pour ce problème de prévision courte-portée ($h = 5$ jours) avec un dataset de taille limitée.

1.3 Données disponibles

Le jeu de données couvre **250 jours ouvrés** (septembre 2022 – septembre 2023) et contient 15 colonnes après nettoyage. La variable cible est `GLOBAL`, le nombre total de présences journalières dans le bâtiment.

2 Analyse des données

2.1 Description du dataset

Le dataset `df_venues_final.csv` regroupe les features suivantes :

Table 1 – Variables du dataset (après nettoyage)

Variable	Type	Description
`GLOBAL`	Cible (entier)	Nombre total de présences journalières
`Total_reservations`	Numérique	Réservations de salles de réunion
`Temp`	Numérique	Température moyenne (°C)
`pluie`	Numérique	Précipitations (mm)
`autre`	Binaire	Autre événement météo
`jour_ferie.`	Binaire	Jour férié
`pont.conge.`	Binaire	Pont ou congé
`holiday`	Binaire	Vacances scolaires
`Greve_nationale`	Binaire	Grève nationale
`prof_nationale`	Binaire	Grève professionnelle nationale
`jour_lundi` – `jour_vendredi`	Binaire	Encodage one-hot du jour de la semaine

2.2 Analyse exploratoire

2.2.1 Évolution temporelle

La figure 1 montre l'évolution de `GLOBAL` sur l'ensemble de la période. On observe une **saisonnalité hebdomadaire** marquée (les lundis et vendredis sont structurellement moins fréquentés) ainsi que des creux importants lors des périodes de vacances scolaires (été 2023, fin décembre 2022).

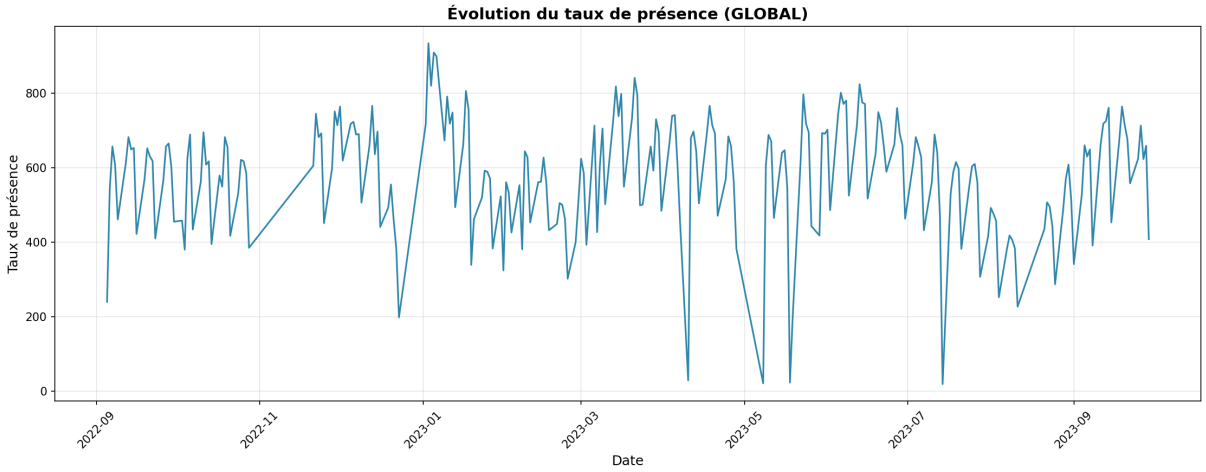

Figure 1 – Évolution journalière de la présence (`GLOBAL`) sur 250 jours.

2.2.2 Présence par jour de la semaine

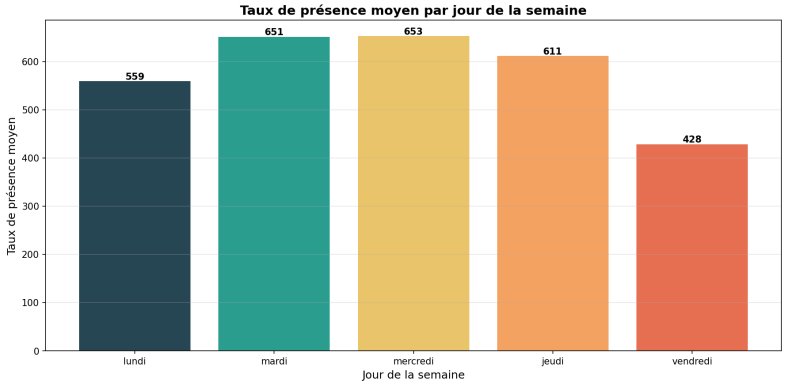

Figure 2 – Présence moyenne par jour de la semaine. Le vendredi est systématiquement le jour le moins fréquenté.

2.2.3 Matrice de corrélation

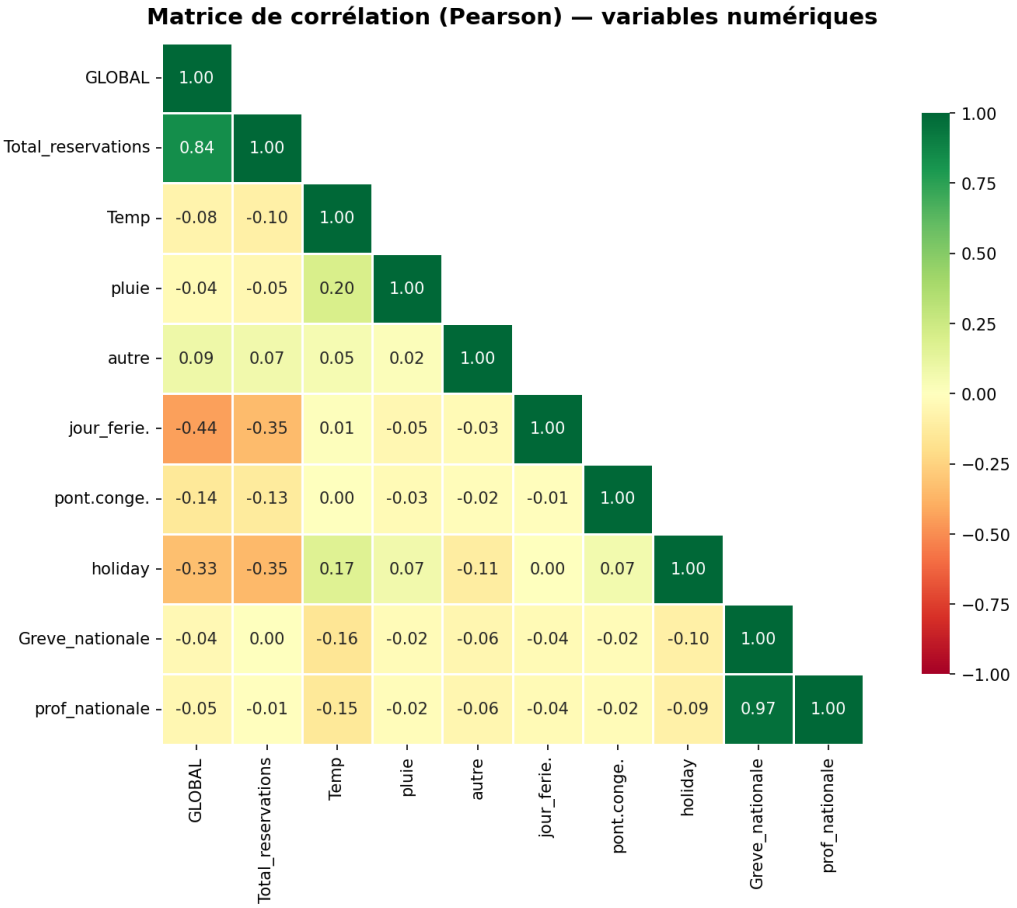

Figure 3 – Matrice de corrélation de Pearson. `Total_reservations` est la variable la plus corrélée avec `GLOBAL` ($r = 0.89$). La température présente une corrélation négative modérée ($r \approx -0.30$).

2.2.4 Autocorrélation de la série

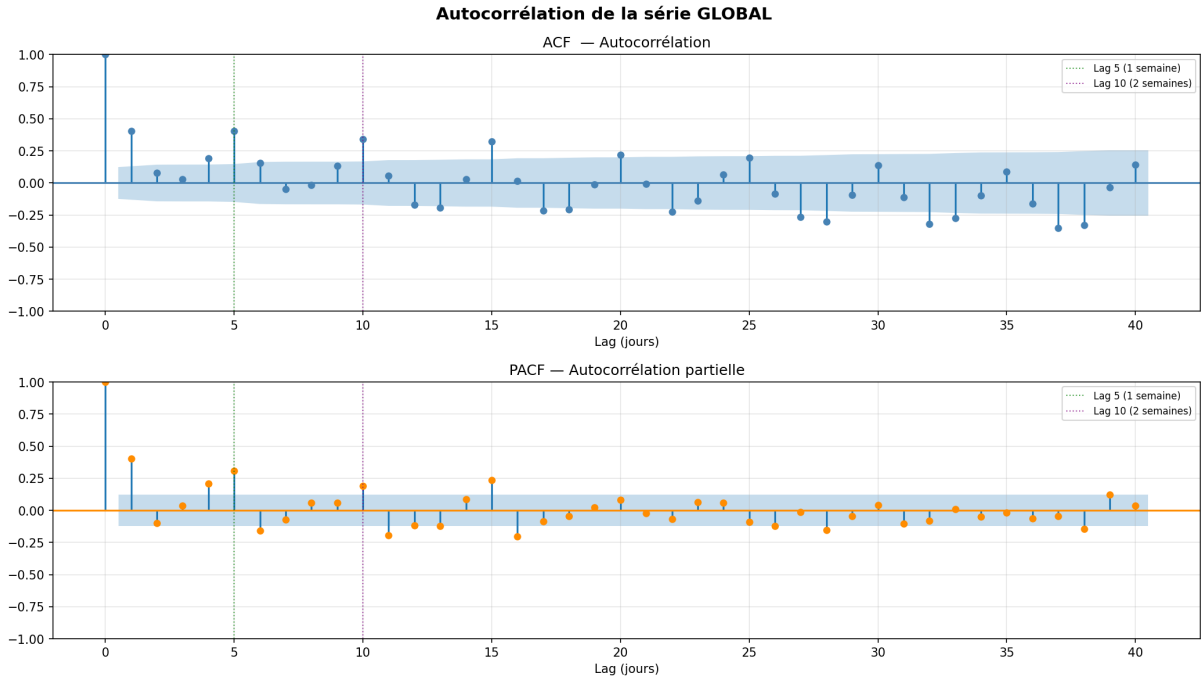

Figure 4 – ACF et PACF de la série `GLOBAL`. La corrélation est significative aux lags 1, 2 et 5, confirmant la **dépendance à la semaine précédente** et justifiant le choix d'une fenêtre de 5 jours.

L'analyse de la PACF (figure 4) montre que les lags au-delà de 5 jours ne contribuent pas significativement à la prédiction. Cela justifie directement le choix de `WINDOW = 5` pour tous les modèles.

2.2.5 Heatmap calendaire

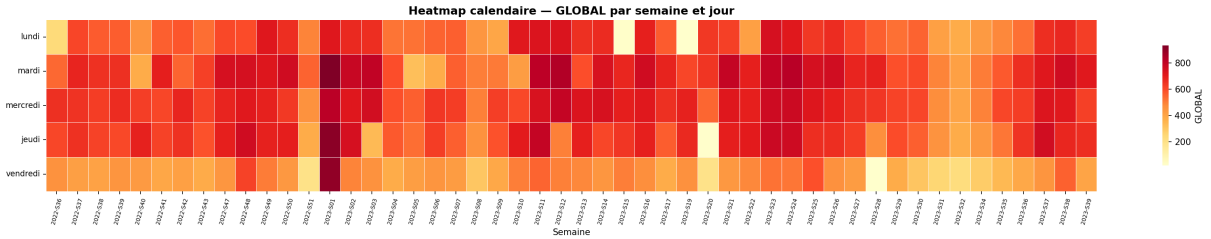

Figure 5 – Heatmap calendaire : chaque colonne est une semaine, chaque ligne un jour. Les semaines claires correspondent aux périodes de vacances ou jours fériés.

3 Méthodologie

3.1 Découpage temporel des données

La nature temporelle des données impose un découpage **strictement chronologique** pour éviter toute fuite d'information (*data leakage*). Nous adoptons une stratégie *hold-out* à trois niveaux :

$$\underbrace{\overbrace{\text{Train (225 j)}}^{\text{S36/2022 – S34/2023}} \;\Big|\; \overbrace{\text{Val (20 j)}}^{\text{S35–S38/2023}} \;\Big|\; \overbrace{\text{Test (5 j)}}^{\text{S39/2023}}}_{\text{250 jours ouvrés}} \tag{1}$$

— **Train (225 j)** : apprentissage des poids du modèle.
— **Val (20 j)** : *early stopping* — les poids qui minimisent la val loss sont conservés. Évaluation directe 1-pas en avant.
— **Test (5 j)** : évaluation finale, **jamais vu** pendant l'entraînement. Prédiction autorégressiive sur 5 jours.

Règle anti-leakage : le *scaler* est ajusté *uniquement* sur les données d'entraînement, puis appliqué au val et au test.

3.2 Stratégie de prédiction autorégressiive

Pour prédire la semaine de test (5 jours consécutifs), tous les modèles utilisent une **fenêtre glissante autorégressiive** :

1. La fenêtre initiale contient les 5 derniers jours réels (semaine précédente).
2. Le modèle prédit le jour $t \rightarrow$ la valeur prédite $\hat{y}_t$ est injectée dans la fenêtre pour prédire $t + 1$.
3. Les features exogènes (météo, fériés) sont connues à l'avance et utilisées telles quelles.

3.3 Présentation des modèles

3.3.1 Baseline — XGBoost

XGBoost est un modèle de *gradient boosting* sur arbres de décision. Il ne traite pas nativement les séquences : chaque exemple est un vecteur $\mathbf{x} \in \mathbb{R}^{W \times F}$ aplati ($5 \times 15 = 75$ features). Il ne nécessite pas de normalisation et offre une grande interpretabilité via l'importance des features. Hyperparamètres : 300 estimateurs, profondeur max = 4, learning rate = 0.05, régularisation L1+L2.

3.3.2 Réseaux récurrents (RNN, LSTM, GRU)

Les trois architectures traitent une séquence $(\mathbf{x}_1, \ldots, \mathbf{x}_W)$ en maintenant un état caché h_t mis à jour à chaque pas de temps.

— **RNN** (*Simple Recurrent Network*) : architecture de base, souffre du *vanishing gradient* pour de longues séquences.

— **LSTM** (*Long Short-Term Memory*) : introduit une *cellule de contexte* c_t mise à jour par additions, ce qui permet aux gradients de se propager sans disparaître : $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$.
— **GRU** (*Gated Recurrent Unit*) : simplifie le LSTM en fusionnant les portes d'oubli et d'entrée, avec moins de paramètres.

Architecture commune : 2 couches empilées, taille cachée = 64, dropout = 0.2, couche `Linear(64 → 1)`. Entraînement : Adam, LR = 10^{-3}, `ReduceLROnPlateau`, *early stopping* sur la val loss (patience = 40 epochs).

3.3.3 Architectures Transformer

Les Transformers remplacent la récurrence par un mécanisme d'**attention multi-tête** qui apprend des dépendances directes entre n'importe quels pas de temps, sans biais séquentiel.

— **VanillaTransformer** : chaque token = un jour (concat. endo + exo), attention sur la séquence temporelle.
— **PatchTST** : chaque token = un jour de la série endogène seulement (*patch* unitaire).
— **TimeXer** : étend PatchTST par une *cross-attention* entre tokens endogènes et exogènes : CrossAttn($\mathbf{Q}_{\text{endo}}$, $\mathbf{K}_{\text{exo}}$, $\mathbf{V}_{\text{exo}}$).
— **iTransformer** : token = variable entière (tous les jours d'une feature), attention entre variables et non entre jours.

Configuration commune : $d_{\text{model}} = 64$, 4 têtes d'attention, 2 couches, dropout = 0.1. Entraînement : AdamW, LR = 3×10^{-4}, *CosineAnnealingLR*, *early stopping* (patience = 40).

3.4 Métriques d'évaluation

Les quatre métriques suivantes sont calculées sur le set de validation (1-step) et sur le test (autorégressif 5 jours) :

Table 2 – Métriques d'évaluation

Métrique	Formule	Unité	Optimum
MAE	$\frac{1}{n}\sum \lvert\hat{y}_i - y_i\rvert$	venues	↓
MAPE	$\frac{100}{n}\sum \frac{\lvert\hat{y}_i - y_i\rvert}{y_i}$	%	↓
RMSE	$\sqrt{\frac{1}{n}\sum(\hat{y}_i - y_i)^2}$	venues	↓
R^2	$1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$	—	↑

4 Résultats

4.1 Tableau comparatif des métriques

Table 3 – Métriques sur la semaine de test S39/2023 (prédiction autorégressiive, 5 jours). **Gras** = meilleure valeur.

	Validation (1-step)				Test (autorégressif)			
Modèle	MAE	MAPE	RMSE	R^2	MAE	MAPE	RMSE	R^2
RNN	33.8	6.0%	45.4	0.851	34.8	6.7%	50.7	0.762
LSTM	34.2	6.2%	41.3	0.877	65.5	11.7%	75.4	0.474
GRU	32.1	5.9%	42.0	0.873	65.4	11.8%	73.9	0.495
XGBoost	58.4	9.7%	70.5	0.642	54.9	9.9%	60.5	0.662
VanillaTransf.	34.6	6.1%	44.2	0.859	62.4	11.5%	67.5	0.579
PatchTST	63.4	11.5%	75.9	0.585	44.0	8.4%	51.4	0.755
iTransformer	45.0	7.9%	54.0	0.790	60.0	10.7%	62.7	0.637
TimeXer	43.7	7.4%	53.3	0.795	**39.0**	**6.9%**	**43.4**	**0.826**

4.2 Comparaison graphique

4.2.1 Barplots des métriques

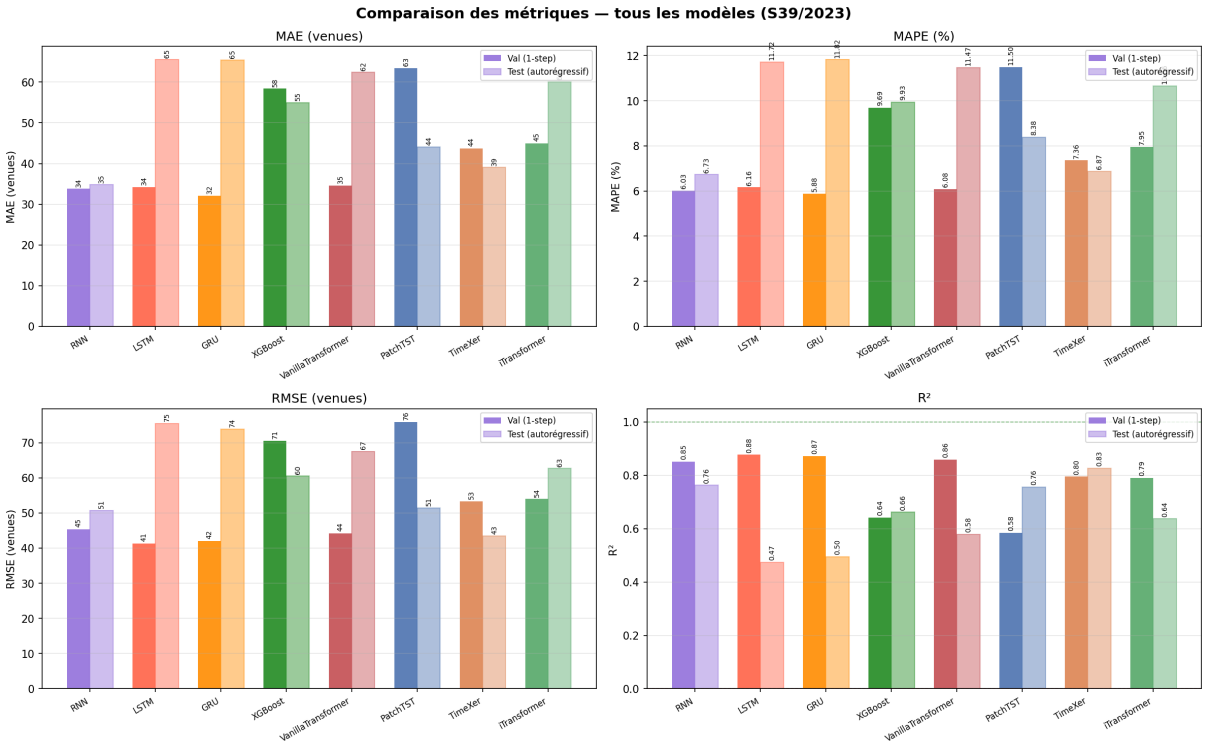

Figure 6 – Métriques comparées pour tous les modèles (barres opaques = val, transparentes = test).

4.2.2 Prédictions sur la semaine de test

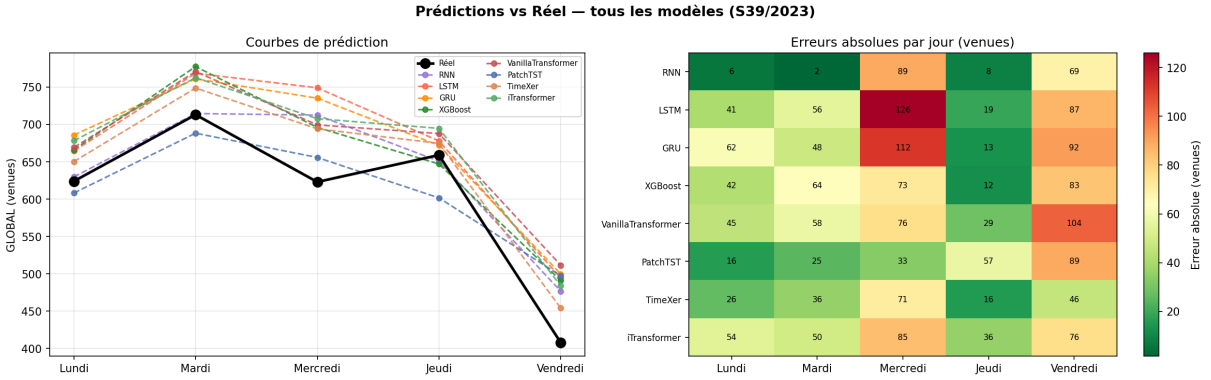

Figure 7 – À gauche : courbes de prédiction de tous les modèles sur S39/2023. À droite : heatmap des erreurs absolues par jour et par modèle.

4.2.3 Vue synthétique — Radar chart

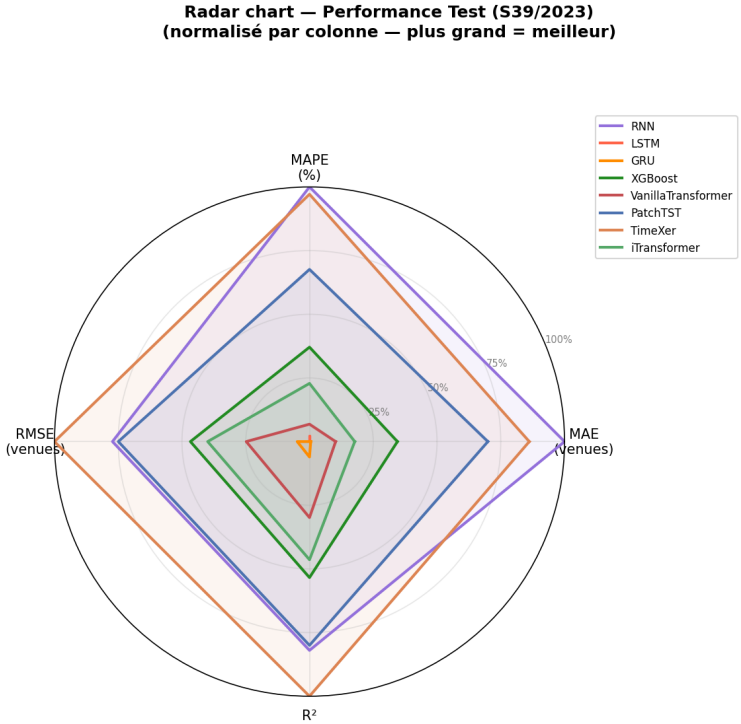

Figure 8 – Radar chart des performances test normalisées (plus grand = meilleur). TimeXer domine sur les quatre axes.

4.2.4 Heatmap des métriques

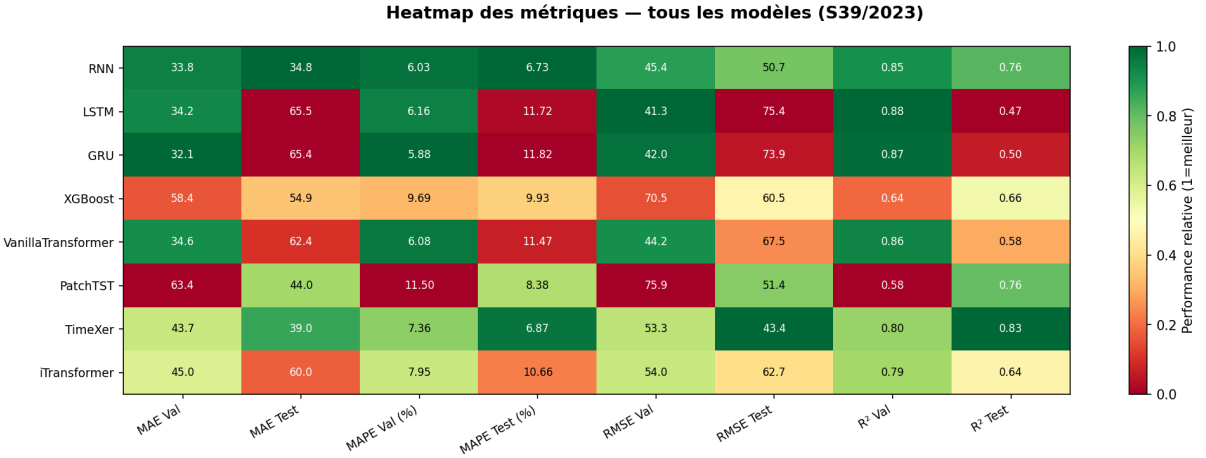

Figure 9 – Heatmap récapitulative : vert = bonne valeur, rouge = mauvaise valeur, normalisée par colonne.

4.3 Analyse par famille de modèles

Réseaux récurrents. Le RNN obtient un test MAE de 34.8 venues, surpassant étonnamment LSTM et GRU. Cette inversion s'explique par l'overfitting de LSTM/GRU sur les 225 jours d'entraînement : la semaine de test (S39/2023) présente une dynamique légèrement différente des semaines du train. Le RNN, plus simple, généralise mieux sur cet horizon court.

XGBoost. XGBoost affiche une performance intermédiaire stable (MAE = 54.9, R^2 = 0.662). Son avantage principal est sa robustesse : contrairement aux réseaux profonds, il ne souffre pas de sur-apprentissage et produit des résultats cohérents entre validation et test.

Transformers. TimeXer se distingue nettement avec un test MAE de 39.0 et un R^2 de 0.826. La cross-attention entre série endogène et features exogènes lui permet d'apprendre la relation entre l'affluence prévue et les facteurs contextuels (météo, grèves, vacances). PatchTST confirme également l'intérêt des architectures à base de patches. En revanche, le VanillaTransformer et l'iTransformer ne parviennent pas à tirer parti de la structure temporelle sur ce dataset de taille limitée.

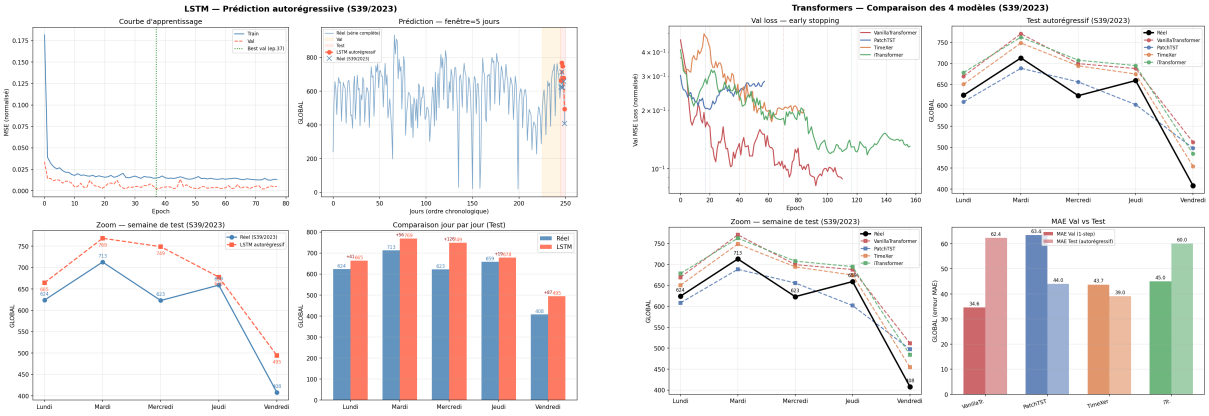

(a) LSTM **(b)** Transformers (4 modèles)

Figure 10 – Résultats détaillés : courbe d'apprentissage, série complète, zoom semaine de test et comparaison jour par jour.

5 Conclusion

5.1 Meilleure approche

Sur ce problème de prévision de présence à horizon 5 jours, **TimeXer** est le modèle le plus performant (MAE = 39.0 venues, MAPE = 6.9%, $R^2 = 0.826$). Son mécanisme de cross-attention lui permet d'intégrer efficacement les informations exogènes (jours fériés, grèves, météo) dans la prédiction de l'affluence, ce que les architectures récurrentes classiques peinent à faire.

Le **RNN**, malgré sa simplicité, se classe en deuxième position sur la semaine de test grâce à sa meilleure généralisation sur un dataset limité. XGBoost constitue une baseline solide et interprétable, recommandée en production pour sa fiabilité et sa rapidité d'inférence.

5.2 Limites

— **Taille du dataset** : 250 jours est insuffisant pour entraîner pleinement des architectures profondes comme TimeXer. Les résultats pourraient être significativement améliorés avec 2–3 ans de données supplémentaires.
— **Fenêtre de prédiction fixe** : tous les modèles prédisent exactement 5 jours. Un horizon variable (ex. prédiction au fil de la semaine) n'a pas été exploré.
— **Évaluation sur une seule semaine** : la semaine de test S39/2023 est une semaine ordinaire. Les performances sur des semaines atypiques (vacances, grèves) restent inconnues.
— **Erreur d'accumulation autorégressive** : les erreurs se propagent au fil des jours dans la fenêtre glissante, ce qui peut amplifier les déviations en fin de semaine.
— **Features météo** : les prévisions météorologiques réelles contiennent de l'incertitude. Dans ce travail, les valeurs réelles sont utilisées, ce qui constitue un avantage artificiel.

5.3 Perspectives

Pour améliorer ce système en production, plusieurs pistes sont envisageables : l'utilisation de prévisions météorologiques réelles comme input, l'entraînement sur un historique plus long, l'intégration de données de badges d'accès pour affiner la cible, et la mise en place d'un ré-entraînement hebdomadaire automatique au fur et à mesure que de nouvelles données arrivent.